IJSA (20xx), Vol. xx, No. yy, 1-5
DOI: https://doi.org/10.29244/ijsa.vxiypno

Indonesian Journal of Statistics and Its Applications
Available at https://ijsa.stats.id
e-ISSN: 2599-0802

PERSONALITY CLASSIFICATION OF *INTROVERT*S AND EXTROVERTS USING LOGISTIC REGRESSION WITH *GRADIENT DESCENT* OPTIMIZATION

Klasifikasi Kepribadian *Introvert* dan *Ekstrovert* Menggunakan Regresi Logistik dengan Optimasi *Gradient descent*

Sandra Berliana Putri[1‡], Dalilah Husna[1], Yulianti Nurdzanah[1], Lilis Indra Purnama Sari[1], Nawwaf Ariq Rabbani[1], and Rahma Anisa[1]

[1]Department of Statistics, IPB University, Indonesia
[‡]corresponding author: sandraberlianaputri@apps.ipb.ac.id

Copyright © 2025 Sandra Berliana Putri, Dalilah Husna, Yulianti Nurdzanah, Lilis Indra Purnama Sari, Nawwaf Ariq Rabbani, and Rahma Anisa. This is an open-access article distributed under the Creative Commons Attribution License, which permits unrestricted use, distribution, and reproduction in any medium, provided the original work is properly cited.

Abstract

The ability to accurately recognize personality types is important in optimizing individual potential, both in the context of education, job placement, and social interaction. One of the most well-known personality concepts is the tendency to be introverted and extroverted. However, public understanding of this concept often leads to misunderstandings. This study aims to build a quantitative personality type prediction model using logistic regression optimized with the gradient descent algorithm. Logistic regression was chosen because it is suitable for classifying binaries and is able to provide interpretation of the influence of each feature. Meanwhile, gradient descent optimization is used because it is computationally efficient, easy to implement, and suitable for large datasets. The data used came from the Kaggle platform with a total of 2900 observations and eight variables, including a response variable in the form of personality type. The modeling results show that logistic regression is able to classify personality types with an accuracy of 91.94%, a precision of 94.24%, a recall of 89.80%, an F1-Score of 91.97%, and an AUC-ROC of 0.89. These findings indicate that gradient descent optimization is able to provide fairly good classification results, while opening up space for behavioral interpretation based on quantitative data.

Keywords: extrovert, gradient descent, introvert, logistic regression, personality.

1. Pendahuluan

Kepribadian merupakan elemen kunci dalam memahami variasi perilaku antar individu (Tae & Bessie, 2021). Salah satu pendekatan yang dikenal untuk menjelaskan kecenderungan kepribadian adalah tipologi *introvert-ekstrovert* yang dikembangkan oleh Carl Jung (Ulin et al., 2022). Menurut Loppies et al. (2020)**,** Individu dengan kecenderungan *introvert* lebih fokus pada dunia internal dan pemikiran pribadi. Menurut Loppies & Badrujaman (2020), Individu dengan kecenderungan *introvert* lebih fokus pada dunia internal dan pemikiran pribadi. Sebaliknya, *ekstrovert* menggambarkan kepribadian yang terfokus pada dunia luar dengan minat dan perhatian yang lebih besar terhadap objek atau aktivitas eksternal. Seiring dengan meningkatnya perhatian publik terhadap isu-isu psikologis, konsep *introvert* dan *ekstrovert* yang awalnya merupakan teori dalam disiplin ilmu kini berkembang menjadi bagian dari identitas yang diadopsi secara luas oleh masyarakat, khususnya generasi muda.

Popularitas konsep ini tidak jarang disertai dengan penyederhanaan yang berpotensi menimbulkan kesalahpahaman, seperti mengidentifikasi *introvert* dengan sifat pemalu atau menganggap *ekstrovert* sebagai orang yang suka bergaul. Padahal, sebagaimana ditegaskan oleh Jung, perbedaan utama di antara keduanya lebih berkaitan dengan kecenderungan ego individu dalam mengarahkan perhatian mereka (Masitoh et al., 2023). Fenomena penyederhanaan ini menunjukkan adanya kesenjangan antara pemahaman populer dengan konsep keilmuan yang lebih kompleks. Oleh karena itu, pendekatan kuantitatif sangat penting dalam mengkaji kepribadian secara objektif. Pemahaman yang lebih akurat terhadap kecenderungan kepribadian memiliki implikasi praktis yang luas, mulai dari strategi pembelajaran yang lebih personal, penempatan kerja yang sesuai dengan karakter, hingga peningkatan efektivitas komunikasi dalam kehidupan sosial. Mengenali tipe kepribadian secara lebih mendalam dapat mengoptimalkan potensi setiap individu melalui pendekatan yang sesuai dengan karakter unik masing-masing. Salah satu metode yang dapat digunakan untuk tujuan ini adalah regresi logistik.

Regresi logistik adalah suatu metode statistik yang digunakan untuk memodelkan hubungan antara satu atau lebih peubah independen dengan peubah dependen biner (Hosmer dan Lemeshor, 2000). Optimasi parameter model regresi logistik dilakukan menggunakan algoritma *gradient descent*, yaitu metode iteratif yang bertujuan meminimalkan fungsi *loss* melalui pembaruan bobot secara bertahap berdasarkan arah penurunan tercepat dari fungsi tersebut. Keunggulan pendekatan ini mencakup efisiensi komputasi, kemampuan untuk menangani dataset berukuran besar, serta kemudahan implementasi (Bishop, 2006). Penelitian ini bertujuan menerapkan regresi logistik yang di optimasi menggunakan algoritma *gradient descent* dalam upaya memprediksi kepribadian berdasarkan indikator perilaku yang terukur. Melalui pemodelan yang tepat, diharapkan pendekatan ini dapat dijembatani antara teori kepribadian dengan realitas sosial yang lebih dinamis dan kompleks.

2. Metodologi

2.1 Bahan dan Data

Data yang digunakan adalah data sekunder yang diperoleh dari *website Kaggle.* Data ini terdiri dari 2900 data dengan 7 peubah bebas denga 1 peubah respon. Peubah respon yang digunakan adalah tipe kepribadian *introvert* dan *ekstrovert*. Peubah yang digunakan dalam penelitian ini dijelaskan pada Tabel 1.

Tabel 1: Daftar peubah yang digunakan

Kode	Nama Peubah	Tipe
Y	Tipe Kepribadian	Kategorik
X_1	Waktu yang dihabiskan sendirian	Numerik
X_2	*Stage fear*	Kategorik
X_3	Kehadiran di acara sosial	Numerik
X_4	Frekuensi keluar rumah	Numerik
X_5	Merasa lelah setelah bersosialisasi	Kategorik
X_6	Jumlah teman dekat	Numerik
X_7	Frekuensi *posting* di media sosial	Numerik

2.2 Metode Penelitian

Analisis data dilakukan menggunakan perangkat lunak Python :

1. *Input* data yang diambil dari *website* Kaggle.
2. Melakukan eksplorasi meliputi pengecekan *missing value*, statistika deskriptif, pengecekan *outlier*, distribusi kelas peubah respon, korelasi antara peubah X dan Y.
3. Melakukan pra-proses data meliputi pemisahan peubah penjelas dan respon, *encoding* pada data kategorik, pengecekan multikolinearitas dan *split* data menjadi data latih dan uji. Pengecekan multikolinearitas menggunakan *Generalized Variance Inflation Factor* (GVIF) menggunakan Persamaan 1(Az-zahra et al., 2021).

   $$GVIF_j = \frac{det\left(R_{X_j}\right) det\left(R_{X_{[-j]}}\right)}{det(R)} \quad (1)$$

   Dengan R_{X_j} merupakan matriks korelasi untuk X_j yaitu peubah independen yang akan dicari GVIF dan suku polinomialnya, $R_{X_{[-j]}}$merupakan matriks korelasi $X_{[-j]}$ yaitu seluruh peubah matriks X selain peubah pada X_j dan R merupakan korelasi seluruh peubah pada matriks X kecuali konstanta.
4. Pemodelan regresi logistik dengan *Batch Gradient descent*. Regresi logistik digunakan untuk memetakan hubungan antara peubah prediktor dengan peubah respon yang memiliki dua kategori atau lebih. Regresi logistik biner merupakan model regresi logistik yang memodelkan kejadian dengan peubah respon bertipe kategori dua pilihan yaitu sukses atau gagal (Tripena et al., 2023). *Gradient descent* merupakan algoritma optimasi yang bertujuan meminimalkan fungsi biaya dengan mencari arah turunan atau gradien paling curam. Algoritma *gradient descent* bergerak ke arah gradien negatif dari fungsi biaya untuk menemukan titik minimum lokal (Ashidiq et al., 2025).
   a. Inisiasi parameter bias dan bobot bernilai 0 sebagai parameter awal.
   b. *Tuning* parameter menggunakan *grid search* terhadap dua *hyperparameter* utama, yaitu *learning rate* dan jumlah iterasi.
   c. Menghitung probabilitas menggunakan fungsi *sigmoid* untuk mengubah *output* linear menjadi nilai antara 0 dan 1 berdasarkan Persamaan 2.

      $$h(x) = \frac{1}{1+e^{-(w^T x+b)}} \quad (2)$$

   d. Menghitung fungsi *loss* untuk mengevaluasi kinerja model menggunakan fungsi *binary cross-entropy* berdasarkan Persamaan 3.

      $$\mathcal{L}(y, \hat{y}) = -\frac{1}{n}\sum_{i=1}^{n}[y_i log(\hat{y}_i) + (1-y_i) log(1-\hat{y}_i) \quad (3)$$

Dengan n merupakan jumlah data, y_i merupakan kelas asli untuk data ke$-i$ serta $\hat{y}_i$ merupakan probabilitas hasil prediksi untuk data ke$-i$.

e. Optimasi parameter dengan algoritma *gradient descent*, dimana parameter diperbarui untuk meminimalkan fungsi *loss* dengan Persamaan 4 dan 5.

$$w^{(t+1)} = w^{(t)} - \alpha \frac{1}{n} \sum_{i=1}^{n} \left(h^{(t)}(x_i) - y_i\right) x_i \quad (4)$$

$$b^{(t+1)} = b^{(t)} - \alpha \frac{1}{n} \sum_{i=1}^{n} \left(h^{(t)}(x_i) - y_i\right) \quad (5)$$

Dengan $w^{(t+1)}$ dan $b^{(t+1)}$ merupakan bobot dan bias pada iterasi ke$-t+1$, $w^{(t)}$ dan $b^{(t)}$ merupakan bobot dan bias pada iterasi ke$-t$, α merupakan *learning rate*, $\left(h^{(t)}(x_i) - y_i\right)$ merupakan error prediksi ke$-t$, serta x_i merupakan data ke$-i$.

f. Melatih model dengan melakukan pembaruan parameter sebanyak jumlah iterasi menggunakan data latih.

g. Melakukan prediksi pada data uji, dimana kelas akhir ditentukan berdasarkan *threshold* yaitu ambang batas probabilitas untuk klasifikasi *output* sebagai berikut.

$$Prediksi = \begin{cases} 1, & jika\ h(x) \geq threshold \\ 0, & jika\ h(x) < threshold \end{cases} \quad (6)$$

Dengan kelas 1 merupakan kepribadian *ekstrovert* dan kelas 0 merupakan kepribadian *introvert*.

5. Evaluasi hasil prediksi menggunakan

a. $Accuracy = \frac{(TruePositive + TrueNegative)}{Jumlah\ Data}$

b. $Precision = \frac{True\ Postive}{(True\ Positive + False\ Positive)}$

c. $Recall = \frac{True\ Positive}{(True\ Positive + True\ Negative)}$

d. $F1 - Score = \frac{2(Precision \times Recall)}{(Precision + Recall)}$

e. *Area Under Curve* (AUC) menghitung area di bawah kurva *Receiver Operating Characteristic* (ROC) yang menunjukkan tingkat probabilitas atau keakuratan model prediksi (Santoso et al., 2024). Nilai AUC dapat diklasifikasikan berdasarkan Tabel 2.

Tabel 2: Klasifikasi hasil AUC

AUC *Range*	Level Klasifikasi
0.9 – 1	Sangat baik
0.8 – 0.9	Baik
0.7 – 0.8	Netral
0.6 – 0.7	Lemah
0.5 – 0.6	Gagal

f. Kurva *Receiver Operating Characteristic* (ROC) merupakan hasil plot antara *sensitivity* dan $(1 - specificity)$ pada keseluruhan rentang titik *cut-off* yang mungkin. Semakin tinggi area yang berada di bawah kurva maka semakin baik model tersebut dalam memprediksi (Nur & Oktora, 2020).

3. Hasil dan Pembahasan

3.1. Eksplorasi Data

3.1.1. Pemeriksaan dan Penanganan *Missing Value*

Tahap awal dalam analisis kali adalah memeriksa keberadaan *missing values* dalam dataset. Hasil menunjukkan bahwa hampir seluruh peubah kecuali peubah kepribadian memiliki *missing values* sesuai dengan Tabel 3. Selanjutnya *missing values* diatasi dengan strategi penghapusan baris yang mengandung *missing values* tersebut. Hal ini dilakukan agar tidak menimbulkan bias yang mungkin muncul akibat teknik imputasi yang tidak tepat. Setelah proses penghapusan, tersisa 2477 baris data yang digunakan untuk analisis lebih lanjut.

Tabel 3: Hasil pemeriksaan *missing values*

Peubah	Jumlah *Missing Values*
Waktu yang dihabiskan sendirian	63
Stage fear	73
Kehadiran di acara sosial	62
Frekuensi keluar rumah	66
Merasa lelah setelah bersosialisasi	52
Jumlah teman dekat	77
Frekuensi posting di media sosial	65
Personality	0

3.1.2. Statistika Deskriptif

Statistik deskriptif digunakan dalam menggambarkan karakteristik umum dari data. Lima peubah numerik yang dianalisis meliputi waktu yang dihabiskan sendiri, kehadiran dalam acara sosial, frekuensi keluar rumah, ukuran lingkaran pertemanan, dan frekuensi *posting* di media sosial. Ringkasan statistik dari masing-masing peubah disajikan pada Tabel 4.

Tabel 4: Statistik deskriptif lima peubah numerik

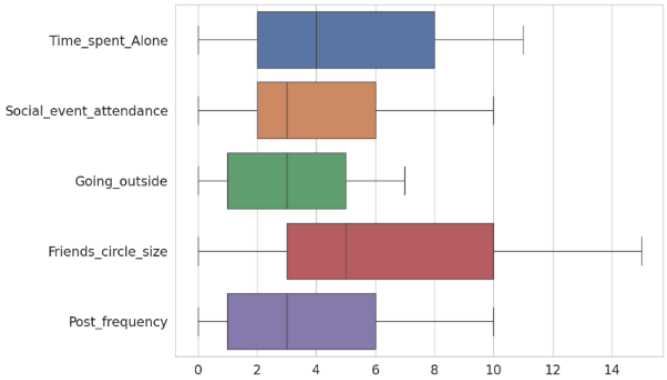
Peubah	*Mean*	Standar Deviasi	*Min*	Q1	Q2 (Median)	Q3	*Max*
Waktu yang dihabiskan sendirian	4,52	3,49	0	2	4	8	11
Kehadiran di acara sosial	3,94	2,90	0	2	3	6	10
Frekuensi keluar rumah	3,01	2,26	0	1	3	5	7
Jumlah teman dekat	6,24	4,31	0	3	5	10	15
Frekuensi posting di media sosial	3,56	2,93	0	1	3	6	10

Berdasarkan Tabel 4, kelima peubah numerik tersebut memiliki rentang nilai serta simpangan baku (standar deviasi) yang relatif mirip satu sama lain. Kondisi ini

menunjukkan bahwa skala pengukuran dan tingkat keragaman antar peubah tidak memiliki perbedaan yang signifikan. Oleh karena itu, proses normalisasi atau standarisasi data, yang biasanya dilakukan untuk mengatasi perbedaan skala atau keragaman antar peubah, tidak diperlukan dalam analisis ini. Dengan kata lain, karena skala dan distribusi nilai peubah sudah cukup seragam, model dapat langsung menggunakan data asli tanpa risiko bias yang disebabkan oleh perbedaan skala.

3.1.3. Pendeteksian *Outlier*

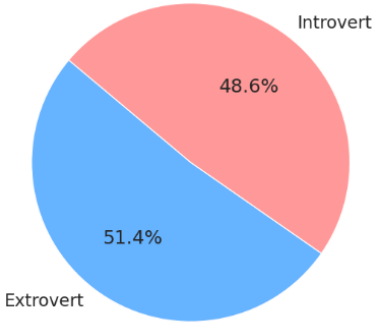
Pendeteksian *outlier* dilakukan menggunakan *boxplot*. Berdasarkan *boxplot* yang disajikan pada Gambar 1, tidak ditemukan *outlier* pada kelima peubah numerik tersebut. Dengan demikian, seluruh data sudah berada dalam rentang wajar dan merepresentasikan variasi alami dalam data.



Gambar 1. *Boxplot* peubah numerik

3.1.4. Distribusi Kelas Peubah Respon

Visualisasi distribusi kelas peubah kepribadian pada Gambar 2 menunjukkan bahwa proporsi antara individu dengan kepribadian *introvert* (48,6%) dan *ekstrovert* (51,4%) relatif seimbang. Keseimbangan distribusi ini penting karena mampu meminimalkan potensi bias klasifikasi, yaitu kecenderungan model untuk lebih sering memprediksi kelas dominan. Selain itu, evaluasi performa model menjadi lebih representatif dan tidak menguntungkan salah satu kelas secara tidak proporsional.



Gambar 2. Diagram lingkaran distribusi kelas peubah respon

3.1.5. Korelasi X terhadap Y

Hubungan antara peubah bebas (X) dengan kepribadian (Y) disajikan pada Tabel 5. Semua peubah memiliki nilai p yang kurang dari 0,05, menunjukkan korelasi signifikan dengan tipe kepribadian. Untuk peubah kategorik digunakan uji *Chi-square*, sedangkan untuk peubah numerik digunakan uji t, menyesuaikan jenis data masing-masing peubah.

Tabel 5: Korelasi X dan Y

Peubah Bebas	*p-value*
Waktu yang dihabiskan sendirian	0,00
Stage fear	0,00
Kehadiran di acara sosial	0,00
Frekuensi keluar rumah	0,00
Merasa lelah setelah bersosialisasi	0,00
Jumlah teman dekat	0,00
Frekuensi *posting* di media sosial	0,00

3.2. *Pra-Processing* Data

3.2.1. Deteksi Multikolinearitas

Data kategorik tidak dapat digunakan langsung dalam pemodelan regresi logistik. Oleh karena itu, dilakukan *encoding* untuk mengubah data kategorik menjadi format numerik. Pada penelitian ini digunakan metode *one-hot encoding* yang menghasilkan kolom biner untuk setiap kategori. Proses tersebut mencegah terjadinya *dummy* peubah *trap* dengan menghilangkan satu kategori dari setiap fitur kategorik.

Multikolinearitas terjadi ketika dua atau lebih peubah bebas memiliki korelasi tinggi satu sama lain yang mampu memengaruhi stabilitas dan interpretasi koefisien dalam model regresi. GVIF digunakan untuk mendeteksi multikolinearitas, terutama terdapat peubah kategori dengan kolom *dummy*. Apabila nilai GVIF melebihi 10, hal tersebut menunjukkan adanya gejala multikolinearitas. Nilai GVIF untuk seluruh peubah yang disajikan pada Tabel 6 sudah berada di bawah 10. Dengan demikian, dapat disimpulkan bahwa tidak terdapat masalah multikolinearitas.

Tabel 6: Hasil GVIF

Peubah Bebas	GVIF
Waktu yang dihabiskan sendirian	0,96
Stage fear_Ya	1,00
Kehadiran di acara sosial	0,97
Frekuensi keluar rumah	0,91
Merasa lelah setelah bersosialisasi_Ya	1,00
Jumlah teman dekat	1,11
Frekuensi *posting* di media sosial	0,93

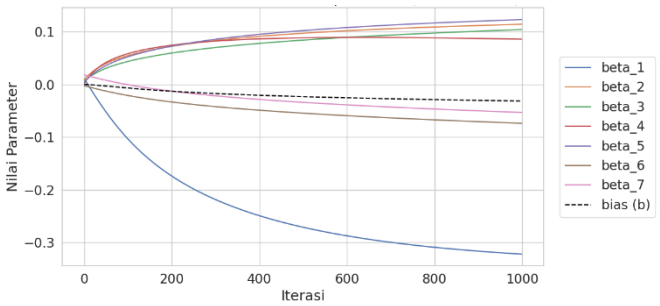
3.2.2. *Splitting* data

Data dibagi menjadi dua subset, yaitu data latih dan uji. Pembagian ini bertujuan melatih model dengan data latih dan menguji performanya dengan data uji. Proporsi pembagian yang digunakan adalah 80% data latih dan 20% data uji. Pada data latih, distribusi kelas untuk peubah target seimbang antara kelas 0 (*introvert*) dan kelas 1 (*ekstrovert*), begitu pula pada data uji sehingga model dapat belajar dan dievaluasi tanpa bias dominasi terhadap satu kelas.

3.3. Pemodelan Regresi Logistik dengan *Gradient Descent*

Pemodelan regresi logistik dilakukan untuk mengklasifikasikan kepribadian individu menjadi dua kelas, yaitu *introvert* dan *ekstrovert* berdasarkan sejumlah fitur. Pendugaan parameter dalam model ini menggunakan algoritma *Batch Gradient descent*. Pada

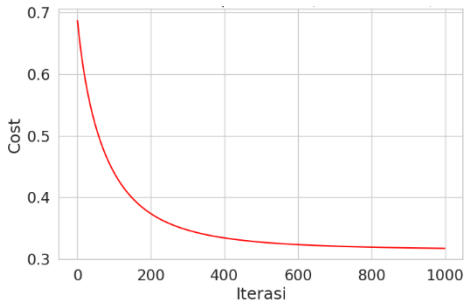
metode ini, seluruh data latih digunakan sekaligus untuk menghitung gradien dan memperbarui parameter bobot serta bias secara iteratif hingga konvergen atau mencapai jumlah iterasi tertentu. Proses ini meminimalkan fungsi *loss* regresi logistik, yaitu *binary cross-entropy loss*, dengan tujuan menemukan nilai parameter yang menghasilkan prediksi probabilitas yang paling mendekati nilai aktual. Untuk memantau proses pelatihan model, dilakukan visualisasi terhadap perubahan nilai parameter β selama iterasi yang disajikan pada Gambar 3.



Gambar 3: Perubahan estimasi parameter β per iterasi

Gambar 3 menunjukkan bahwa semua parameter mengalami perubahan signifikan di awal iterasi. Kemudian nilai parameter perlahan mulai stabil yang menunjukkan proses konvergensi telah tercapai. Beberapa parameter terlihat memberikan pengaruh meningkat serta menurun, sedangkan nilai bias mengalami penyesuaian secara bertahap.

Grafik nilai fungsi *cost* terhadap jumlah iterasi, seperti ditunjukkan pada Gambar 4, menunjukkan bahwa proses pelatihan berjalan secara efektif. *Cost function* mengalami penurunan yang konsisten hingga mendekati nilai minimum, menandakan bahwa model terus memperbaiki prediksinya seiring waktu. Penurunan ini juga mengindikasikan bahwa parameter semakin mendekati nilai optimal dan model mampu belajar dengan baik berdasarkan data tersebut. Sebagai langkah lanjutan, dilakukan proses *tuning hyperparameter* untuk memperoleh kombinasi parameter yang menghasilkan akurasi prediksi terbaik.



Gambar 4. Grafik nilai fungsi *loss* (*cost*)

3.3.1. Tuning Hyperparameter

Model regresi logistik ini di optimasi dengan pendekatan *grid search* terhadap dua *hyperparameter* utama, yaitu *learning rate* dan jumlah iterasi. *Learning rate* mengatur seberapa besar langkah pembaruan parameter serta jumlah iterasi menentukan berapa kali proses pembaruan bobot dan bias. Setelah proses *tuning*, diperoleh kombinasi parameter terbaik berdasarkan akurasi tertinggi, yaitu *learning rate* 0,001 dan jumlah

iterasi 1000, dengan *threshold* 0,5 dengan *accuracy* sebesar 91,94%, *precision* 94,24%, *recall* 89,80%, *F1-score* 91,97%, dan AUC 88,95%.

3.3.2. Persamaan Regresi Logistik

Proses pelatihan model menghasilkan persamaan logit sebagai berikut.

$$logit(p) = 0{,}03 - 0{,}32X_1 + 0{,}11X_2 + 0{,}10X_3 + 0{,}09X_4 + 0{,}12X_5 - 0{,}07X_6 - 0{,}05\,X_7 \quad (5)$$

p merupakan probabilitas seseorang diklasifikasikan sebagai *ekstrovert* serta peubah $X_1 - X_7$ merepresentasikan peubah bebas dalam dataset. Tanda negatif dan positif pada koefisien menunjukkan arah pengaruh masing-masing peubah terhadap kemungkinan seseorang menjadi *ekstrovert*. Koefisien $X_1, X_6,$ dan X_7 memiliki tanda negatif, peningkatan nilai pada fitur tersebut akan menurunkan probabilitas individu untuk diklasifikasikan sebagai *ekstrovert*. Sebaliknya, $X_2, X_3, X_4,$ dan X_5 memiliki tanda positif, maka peningkatan nilai pada fitur tersebut akan meningkatkan probabilitas individu untuk diklasifikasikan sebagai *ekstrovert*.

Koefisien tersebut dapat diinterpretasikan menggunakan *odds ratio* dengan meng-exponensialkan nilai koefisien, yaitu e^{β_i}. *Odds* menyatakan probabilitas yang membagi probabilitas terjadinya suatu kejadian dengan probabilitas tidak terjadinya kejadian tersebut (Aristawidya et al., 2024). *Odds ratio* menunjukkan seberapa besar probabilitas seseorang diklasifikasikan sebagai *ekstrovert* setiap kali nilai suatu peubah naik satu tingkat dengan asumsi peubah lain tetap sama. Berikut interpretasi koefisien logit dan *odds ratio* masing-masing peubah pada Tabel 4.

Tabel 4: Interpretasi koefisien

Peubah	Koefisien (β_i)	*Odds ratio* (e^{β_i})	Interpretasi
X_1 (Waktu yang dihabiskan sendirian)	-0,32	0,73	Setiap tambahan 1 jam waktu sendiriar akan menurunkan logit (log *odds*) menjadi *ekstrovert* sebesar 0,32 satuan. *Odds* (probabilitas relatif) untuk menjadi *ekstrovert* menjadi 0,73 kali lebih kecil.
X_2 (*Stage fear*_Ya)	0,11	1,12	Setiap peningkatan 1 tingkat *stage fea* akan meningkatkan logit sebesar 0,11. Odds untuk menjadi *ekstrovert* menjad 1,11 kali lebih besar.
X_3 (Kehadiran di acara sosial)	0,10	1,11	Setiap tambahan 1 kali hadir di acara sosiall menaikkan logit sebesar 0,10. *Odds* menjadi *ekstrovert* menjadi 1,11 kal lebih besar.
X_4 (Frekuensi keluar rumah)	0,09	1,09	Setiap tambahan 1 kali keluar rumah menaikkan logit sebesar 0,09. *Odds* menjadi *ekstrovert* menjadi 1,09 kal lebih besar.
X_5 (Merasa lelah setelah sosialisasi_Ya)	0,12	1,13	Setiap peningkatan 1 tingkat kelelahar setelah bersosialisasi menaikkan logi sebesar 0,12. *Odds* menjadi *ekstrover* menjadi 1,13 kali lebih besar.

Peubah	Koefisien (β_i)	*Odds ratio* (e^{β_i})	Interpretasi
X_6 (Jumlah teman dekat)	-0,07	0,93	Setiap tambahan 1 teman deka menurunkan logit sebesar 0,132. *Odds* menjadi *ekstrovert* menjadi 0,88 kal lebih kecil.
X_7 (Frekuensi *posting* media sosial)	-0,05	0,95	Setiap tambahan 1 kali *posting* di media sosial menurunkan logit sebesar 0,142. *Odds* menjadi *ekstrovert* menjadi 0,87 kal lebih kecil.

Setelah diperoleh nilai logit, probabilitas dikalkulasi menggunakan fungsi *sigmoid* berdasarkan Persamaan (2). Jika nilai probabilitas p lebih besar atau sama dengan nilai *threshold* 0,5 maka individu diklasifikasikan sebagai *ekstrovert*. Jika nilai tersebut kurang dari 0,5 maka diklasifikasikan *introvert*.

Sebagai ilustrasi, prediksi kelas dilakukan pada dua individu dengan karakteristik berbeda. Individu pertama memiliki nilai X_1 hingga X_7 masing-masing 2, 1, 7, 6, 0, 4, dan 3. Nilai tersebut dimasukkan ke Persamaan (5).

$$logit(p)_1 = 0{,}03 - 0{,}32(2) + 0{,}11(1) + 0{,}10(7) + 0{,}09(6) + 0{,}12(0) - 0{,}07(4) - 0{,}05(3) = 0{,}31$$

$$p_1 = \frac{1}{1 + e^{-0{,}31}} = 0{,}58$$

Karena $p > 0{,}5$ individu pertama ini dikasifikasikan sebagai *ekstrovert*. Lalu, individu kedua memiliki nilai X_1 hingga X_7 sebesar 6, 0, 2, 1, 1, 5, dan 1. Nilai tersebut juga dimasukkan ke Persamaan (5).

$$logit(p)_1 = 0{,}03 - 0{,}32(6) + 0{,}11(0) + 0{,}10(2) + 0{,}09(1) + 0{,}12(1) - 0{,}07(5) - 0{,}05(1) = -1{,}88$$

$$p_1 = \frac{1}{1 + e^{-(-1{,}88)}} = 0{,}13$$

Karena $p < 0{,}5$ individu kedua ini dikasifikasikan sebagai *introvert*.

3.3.4. Prediksi Data Uji

Tabel 5: *Confussion Matrix*

		Aktual	
		Introvert	*Ekstrovert*
Prediksi	*Introvert*	227	14
	Ekstrovert	26	229

Model ini menghasilkan *confusion matrix* sesuai pada Tabel 5 yang berhasil mengklasifikasikan 227 individu *introvert* dan 229 individu *ekstrovert* dengan benar pada data uji. Sebanyak 14 *introvert* salah prediksi sebagai *ekstrovert* (*false positive*) dan 26 *ekstrovert* salah diklasifikasikan sebagai *introvert* (*false negative*). Dengan total 456 prediksi benar dari 496 data, model menunjukkan kinerja klasifikasi yang cukup akurat.

3.3.5. Evaluasi Model

Evaluasi performa model regresi logistik dilakukan pada data latih dan data uji menggunakan lima metrik utama. Metrik tersebut antara lain *accuracy*, *precision*, *recall*, *F1-score*, dan AUC-ROC. Hasil evaluasi model disajikan pada Tabel 6.

Tabel 6: Metrik Evaluasi Model

Metrik Evaluasi	Data Latih	Data Uji
Accuracy	92,68%	91,94%
Precision	93,79%	94,24%
Recall	91,85%	89,80%
F1-Score	92,81%	91,97%
AUC-ROC	90,00%	89,00%

Tabel 6 menunjukkan bahwa model memiliki *accuracy* tinggi baik pada data latih (92,68%) maupun data uji (91,94%) yang menandakan bahwa model memiliki kemampuan yang baik dalam generalisasi pola. *Precision* dan *recall* juga seimbang dengan nilai tinggi maka model dapat mengidentifikasi kelas dengan tingkat kesalahan yang rendah serta tidak banyak melewatkan data yang seharusnya terklasifikasi dengan benar. *F1-score* memperkuat temuan tersebut karena menggabungkan presisi dan *recall* dalam satu ukuran yang stabil di atas 91% yang menunjukkan bahwa model mampu menjaga keseimbangan keduanya. AUC-ROC di atas 89% menunjukkan bahwa model cukup baik dalam membedakan karakteristik antara *introvert* dan *ekstrovert* sesuai dengan klasifikasi pada Tabel 2. Secara keseluruhan, metrik evaluasi mencerminkan bahwa regresi logistik dengan *gradient descent* bekerja optimal untuk klasifikasi biner kepribadian dengan risiko *overfitting* yang rendah dan performa konsisten di dua set data.

4. Simpulan dan Saran

Penelitian ini menunjukkan bahwa regresi logistik yang di optimasi dengan *gradient descent* dapat digunakan untuk mengklasifikasikan kepribadian individu melalui pendekatan kuantitatif ke dalam dua kategori, yaitu *introvert* dan *ekstrovert*. Model dikembangkan dengan mempertimbangkan tujuh fitur dan pelatihan dilakukan menggunakan algoritma *gradien descent* untuk mengoptimasi parameter model. Selanjutnya dilakukan *tuning hyperparameter* menggunakan *grid* untuk menentukan kombinasi terbaik dari *learning rate* dan jumlah iterasi. Kombinasi terbaik didapatkan ketika *learning rate* 0,001 dan iterasi sebanyak 1000, dengan *threshold* 0,5. Model menghasilkan performa klasifikasi yang cukup baik dengan *accuracy* sebesar 91,94%, *precision* 94,24%, *recall* 89,80%, *F1-Score* 91,97%, dan AUC-ROC 89% dimana 456 dari 496 individu di klasifikasikan dengan benar.

Persamaan regresi menunjukkan bahwa probabilitas p mempresentasikan kemungkinan individu diklasifikasikan sebagai *ekstrovert*. Peubah seperti waktu menyendiri, jumlah teman dekat, dan frekuensi *posting* di media sosial memiliki koefisien negatif, peningkatannya akan menurunkan peluang klasifikasi *ekstrovert*. Sebaliknya, peubah *stage fear*, kehadiran di acara sosial, frekuensi keluar rumah, dan rasa lelah setelah bersosialisasi memiliki koefisien positif, sehingga cenderung meningkatkan probabilitas klasifikasi sebagai *ekstrovert*. Temuan ini menunjukkan bahwa regresi logistik dengan optimasi *gradient descent* tidak hanya akurat, tetapi juga memberikan interpretasi yang jelas.

Saran untuk penelitian selanjutnya, model regresi logistik dapat dibandingkan dengan algoritma lain seperti Support Vector Machine (SVM), Random Forest, atau Neural Network guna memperoleh performa klasifikasi yang lebih optimal. Selain itu, dapat dilakukan analisis terhadap fitur signifikan melalui seleksi fitur atau interpretasi model lanjutan seperti SHAP yang dapat memberikan pemahaman yang lebih mendalam. Penelitian lanjutan dapat mempertimbangkan dimensi kepribadian yang lebih luas, menggunakan data multikategori, serta menggali potensi data real temporal, seperti aktivitas media sosial harian untuk prediksi yang lebih kontekstual dan dinamis.

Daftar Pustaka

Aristawidya, R., Indahwati, I., Erfiani, E., Fitrianto, A., & A. A., M. (2024). Perbandingan Analisis Regresi Logistik Biner Dan Naïve Bayes Classifier Untuk Memprediksi Faktor Resiko Diabetes. *Jurnal Lebesgue : Jurnal Ilmiah Pendidikan Matematika, Matematika Dan Statistika*, *5*(2), 782–794. https://doi.org/10.46306/lb.v5i2.617

Ashidiq, M. F., Muflikhah, L., & Setiawan, B. D. (2025). *Deteksi Nefropati Diabetik Pada Pasien Diabetes Melitus Menggunakan Regresi Logistik*. *9*(2), 1–9.

Az-zahra, A. A., Marsaoly, A. F., Lestyani, I. P., Salsabila, R., & Madjida, W. O. Z. (2021). Penerapan Algoritma K-Modes Clustering Dengan Validasi Davies Bouldin Index Pada Pengelompokkan Tingkat Minat Belanja Online Di Provinsi Daerah Istimewa Yogyakarta. *Jurnal MSA (Matematika Dan Statistika Serta Aplikasinya)*, *9*(1), 24. https://doi.org/10.24252/msa.v9i1.18555

Bishop, C.M. (2006) *Pattern Recognition and Machine Learning*. Springer, Berlin. https://link.springer.com/book/9780387310732

Hosmer D.W. and Lemeshow, S. (2000) *Applied Logistic Regression*. 2nd Edition, Wiley, New York. https://doi.org/10.1002/0471722146

Loppies, M., & Badrujaman, A. (2020). *Seminar Nasional Pembelajaran Sejarah (SNPS UNS 2020) SHEs: Conference Series 3 (2) (2020) 221-232 Profile of Extrovert and Introvert Personality and The Implications in Problem Based History Learning*. *3*(2), 221–232. https://jurnal.uns.ac.id/shes

Nur, M. R. F., & Oktora, S. I. (2020). Analisis Kurva Roc Pada Model Logit Dalam Pemodelan Determinan Lansia Bekerja Di Kawasan Timur Indonesia. *Indonesian Journal of Statistics and Its Applications*, *4*(1), 116–135. https://doi.org/10.29244/ijsa.v4i1.524

Santoso, H. T., Felmidi, F. A., Nur, A., Ristyawan, A., & Daniati, E. (2024). *Analisis Kinerja Algoritma Data Mining pada Klasifikasi Tingkat Obesitas dengan K-Fold Cross Validation dan AUC*. *8*, 113–122.

Masitoh, S., Meriyati, & Santoso, A. (2023). Pengaruh Model Pembelajaran Kooperatif Tipe Jigsaw Dan Kemandirian Terhadap Hasil Belajar Kognitif Matematika Siswa. *Jurnal Pendidikan Dasar*, *13*(2), 87–98. https://doi.org/10.21009/jpd.v13i2.29411

Tae, B. E., & Bessie, J. L. D. (2021). Pengaruh Gaya Hidup Dan Kelompok Referensi Terhadap Minat Membeli Ulang (Repurchase Intention) (Survei Pada Pelanggan the Kings Resto Kupang). *Transformatif*, *10*(1), 27–45. https://doi.org/10.58300/transformatif.v10i1.162

Tripena, A., Maharsi, R., Lianawati, Y., & Setyawan, A. A. (2023). Analisis Faktor-Faktor yang Mempengaruhi Kemiskinan Rumah Tangga di Desa Kotayasa melalui Pendekatan Regresi Logistik Biner. *Jurnal Elektro Luceat*, *9*(2).

Ulin, N., Latifah, M. M. U., & Nafisa, A. (2022). Sultan Idris Journal of Psychology and Education. *Sultan Idris Journal of Psychology and Education*, *1*(2), 1–14.